Reconnaître un avion à 3 niveaux

Projet 1 du cours de deep learning sur les images. Titouan Fleurent, CNAM, novembre 2026.

En bref

Reconnaître la variante exacte d'un avion sur une photo, c'est difficile. Et toutes les erreurs ne se valent pas : confondre un 737-800 avec un 737-900, ce n'est pas très grave, mais le confondre avec un A320, si. Dans ce projet, je regarde si on peut faire moins d'erreurs graves en donnant au réseau la hiérarchie des avions (constructeur, famille, variante).

J'ai comparé 3 modèles sur le dataset FGVC-Aircraft, avec 3 entraînements par modèle. Sur le test, les 2 modèles qui utilisent la hiérarchie font 14 à 16 % d'erreurs graves en moins, et ils ne reconnaissent pas moins de variantes. Je ne peux pas les départager sur les erreurs, mais le modèle à soft labels se contredit beaucoup moins entre les niveaux.

1. La question

Un réseau à qui on donne la hiérarchie des classes fait-il des erreurs moins graves, et est-ce que ça lui coûte des bonnes réponses ? Le projet part de 2 articles : Maji et al. (2013), qui présentent le dataset, et Bertinetto et al. (2020), qui proposent de juger un modèle sur la gravité de ses erreurs, et pas seulement sur leur nombre.

2. Les données

- FGVC-Aircraft : 10 000 photos, 30 constructeurs, 70 familles et 100 variantes (environ 100 images par variante).
- J'ai gardé les splits officiels : 3 334 images pour l'entraînement, 3 333 pour la validation et 3 333 pour le test. Le modèle ne s'entraîne que sur les 3 334 premières, soit environ 33 images par variante.
- J'enlève d'abord le bandeau de 20 px en bas des photos. Il contient le nom du photographe, et le modèle pourrait s'en servir au lieu de regarder l'avion.
- Je redimensionne les images en carré de 257 px (recadrer directement couperait le nez et la queue), puis je recadre à 224 px : au hasard à l'entraînement, au centre à l'évaluation.
- À l'entraînement, j'ajoute des variations : recadrage au hasard, miroir horizontal, luminosité, contraste et saturation (20 %). Les images sont normalisées comme pour ImageNet, puisque le réseau a été pré-entraîné dessus.

3. La méthode

3.1 Les 3 modèles

Les 3 modèles ont le même réseau (EfficientNet-B0 pré-entraîné sur ImageNet) et les mêmes réglages. Seule la façon de leur donner la hiérarchie change.

Modèle	Têtes	Fonction de perte
Plat	1 (100 variantes)	Cross-entropy, label smoothing de 0,1
3 têtes	3 (30, 70, 100)	CE variante + 0,5 x (CE constructeur + CE famille)
Soft labels	1 (100 variantes)	Cross-entropy vers une cible étalée : softmax(-10 x hauteur / 3)

La hauteur mesure la distance entre 2 variantes dans la hiérarchie : 0 si c'est la même variante, 1 si c'est la même famille, 2 si c'est le même constructeur et 3 si les constructeurs sont différents. Avec les soft labels, la bonne variante garde un poids de 0,787 dans la cible, et le reste va surtout aux variantes proches.

Les modèles à une seule tête ne prédisent que la variante. Pour avoir la famille et le constructeur, j'additionne les probabilités des variantes concernées.

3.2 L'entraînement

- 3 epochs avec le réseau pré-entraîné gelé (BatchNorm comprises), pour que seules les têtes apprennent, puis 20 epochs où tout le réseau apprend.
- AdamW, avec un learning rate de 1e-4 pour le réseau et de 1e-3 pour les têtes, un weight decay de 1e-4, une décroissance en cosinus et des batchs de 32.
- Sur MacBook Air M4 (GPU MPS), une epoch prend environ 85 à 105 s. Les 9 entraînements ont pris un peu moins de 5 h.

3.3 Comment j'évalue

- Pour chaque entraînement, je garde le modèle qui a la meilleure accuracy sur les variantes en validation.
- J'ai écrit et figé mon protocole avant de toucher au test (results/protocole_fige.md). Le test n'a été lancé qu'une seule fois.
- Les résultats sont des moyennes et des écarts-types sur 3 graines.
- Pour comparer 2 modèles, j'utilise un bootstrap apparié sur les images (2 000 tirages, intervalle de confiance à 95 %), avec les prédictions moyennées sur les 3 graines.

4. Les résultats sur le test

Métrique	Plat	3 têtes	Soft labels
Accuracy variante (%)	68,7 ± 0,2	69,6 ± 0,6	69,6 ± 0,4
Accuracy famille (%)	79,8 ± 0,4	81,8 ± 0,2	80,7 ± 0,5
Accuracy constructeur (%)	86,4 ± 0,1	85,9 ± 0,1	87,3 ± 0,4
Top-5 variante (%)	89,7 ± 0,3	90,7 ± 0,2	91,4 ± 0,1
Gravité moyenne, toutes images	0,676 ± 0,002	0,622 ± 0,011	0,626 ± 0,010
Gravité moyenne d'une erreur	2,16 ± 0,01	2,05 ± 0,01	2,06 ± 0,01
Erreurs graves (% des images)	14,9 ± 0,2	12,4 ± 0,3	12,8 ± 0,3
Cohérence des 3 niveaux (%)	91,9 ± 0,3	83,7 ± 0,1	95,4 ± 0,1

Tableau 1. Test, moyenne ± écart-type sur 3 graines. Une erreur faite au hasard aurait une gravité de 2,91.

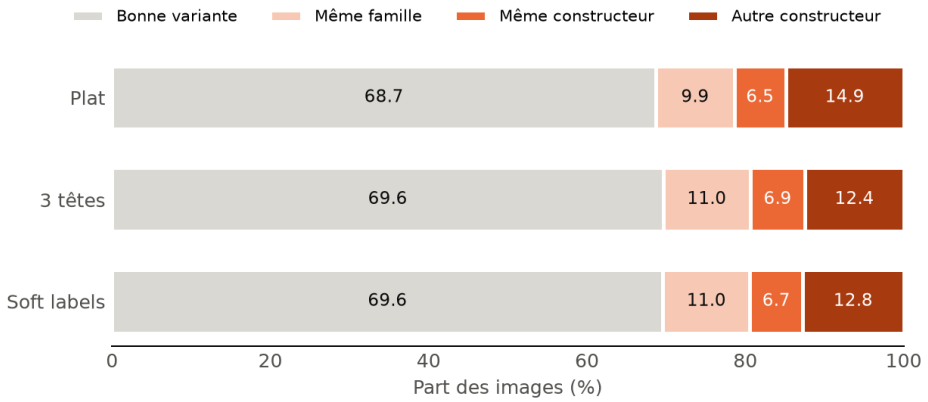


Figure 1. Répartition des images selon la gravité de la prédiction (test, moyenne sur 3 graines).

Différence	Accuracy variante (pts)	Gravité moyenne	Erreurs graves (pts)
3 têtes - Plat	+0,95 [0,23 ; 1,60]	-0,054 [-0,070 ; -0,037]	-2,44 [-2,99 ; -1,88]
Soft - Plat	+0,89 [0,36 ; 1,45]	-0,050 [-0,064 ; -0,036]	-2,13 [-2,66 ; -1,59]
Soft - 3 têtes	-0,06 [-0,77 ; 0,68]	+0,004 [-0,013 ; 0,020]	+0,31 [-0,26 ; 0,91]

Tableau 2. Différences sur le test, avec intervalle de confiance à 95 % (bootstrap apparié).

Ce que j'en retiens

- Les 2 modèles qui utilisent la hiérarchie font moins d'erreurs graves que le modèle plat : 16 % de moins pour les 3 têtes et 14 % pour les soft labels. Dans les 2 cas, l'intervalle exclut zéro.
- Ça ne coûte rien sur les variantes, on gagne même environ 1 point. Ce gain reste petit (pour les 3 têtes, l'intervalle est proche de zéro), donc je ne m'appuie pas dessus.
- Je ne peux pas départager les 3 têtes et les soft labels sur les 3 critères testés : tous les intervalles contiennent zéro.
- La vraie différence est ailleurs : le modèle à 3 têtes se contredit sur 16 % des images, parce que ses têtes sont indépendantes. Les soft labels arrivent à 95 % de cohérence avec une seule tête. C'est pour ça que je les ai gardés pour la démo (choix fait sur la validation, avant le test).
- Le modèle à 3 têtes fait un peu moins bien que le plat sur le constructeur en test (85,9 % contre 86,4 %), alors qu'il faisait mieux en validation (86,4 % contre 85,7 %). Je ne peux donc pas dire qu'il est meilleur à ce niveau.

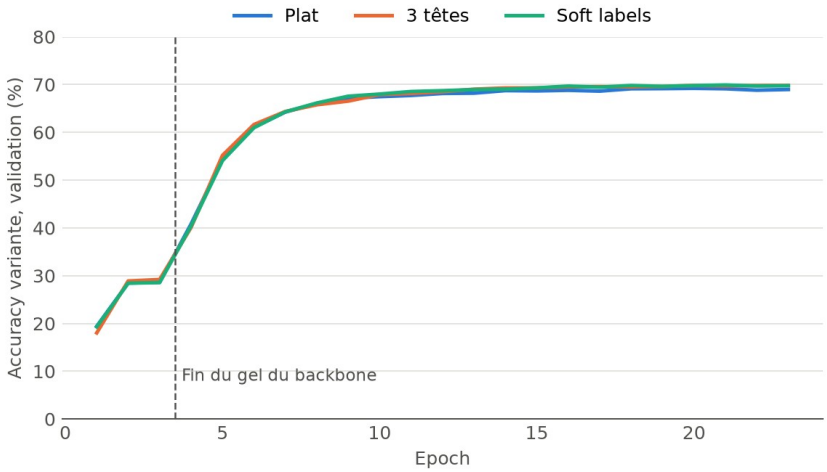


Figure 2. Accuracy sur les variantes en validation, epoch par epoch. Le plus gros gain arrive quand on dégèle le réseau.

5. Où le modèle se trompe

Vraie variante	Variante prédite	Images (sur ~33)	Hauteur
C-47	DC-3	15,3	2
E-190	E-195	14,0	1
MD-11	DC-10	11,7	2
DC-3	C-47	11,3	2
A340-200	A340-300	10,7	1
BAE 146-300	BAE 146-200	10,3	1

Tableau 3. Les confusions les plus fréquentes (soft labels, test, moyenne sur 3 graines).

- Le modèle confond surtout des avions très proches : des versions plus ou moins longues du même avion, ou des avions dérivés l'un de l'autre (le C-47 est la version militaire du DC-3).
- La hiérarchie du dataset n'est pas parfaite : le C-47 et le DC-3 sont dans 2 familles différentes, donc cette confusion compte en hauteur 2 alors que les avions se ressemblent énormément.
- Les variantes les plus dures : 737-300 (26 %), 767-300 (33 %), C-47 (36 %), 737-800 (38 %), 747-200 (38 %) et A320 (38 %). Les mieux reconnues ont une forme bien à elles : Il-76, Eurofighter Typhoon et SR-20 (97 %).
- Les variantes diffèrent souvent par la longueur du fuselage ou le nombre de hublots, ce qui se voit mal à 224 px. C'est une hypothèse : il faudrait refaire un entraînement à plus haute résolution pour la vérifier.

6. Où le modèle regarde (Grad-CAM)

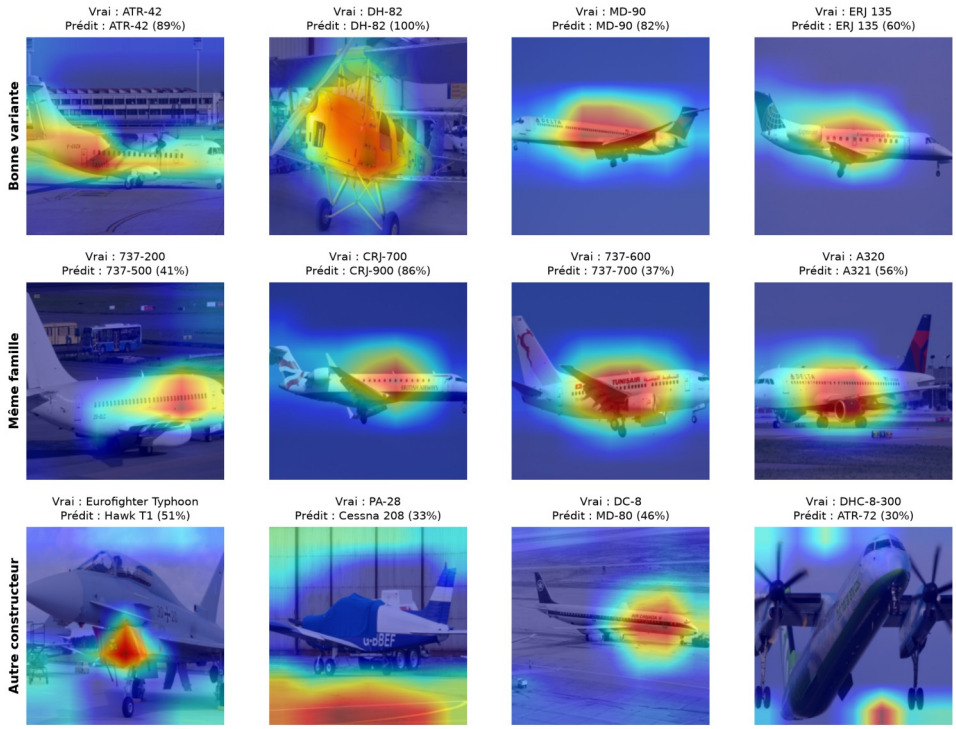


Figure 3. Images de validation tirées au hasard. Ligne 1 : bonne variante. Ligne 2 : même famille. Ligne 3 : autre constructeur.

Grad-CAM montre les zones qui ont le plus compté dans la prédiction. Sur cette planche, pour les bonnes réponses et les erreurs dans la même famille, le modèle regarde presque toujours l'avion.

Pour les erreurs graves, il regarde plusieurs fois le sol ou le fond (PA-28, DHC-8). Il a peut-être été gêné par le décor sur ces images.

Ça reste une observation sur 12 images, pas une preuve. Pour le mesurer proprement, il faudrait des masques qui délimitent les avions.

7. La démo

J'ai fait une petite application Gradio (app.py) : on met une photo, et elle affiche les 3 meilleures réponses à chaque niveau et la carte Grad-CAM. Testée en local sur un exemple de validation : A380 reconnu à 95 %.

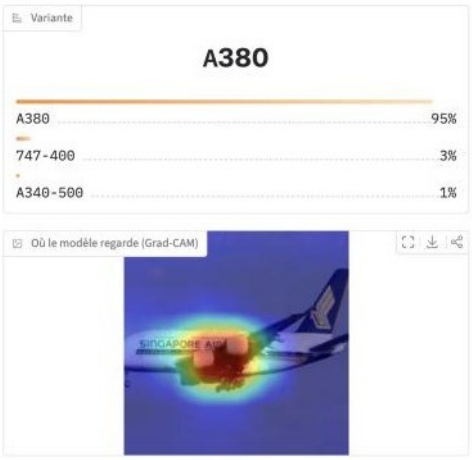


Figure 4. La démo en local.

8. Les limites

- Je n'ai testé qu'une architecture et qu'une résolution. Je n'ai pas fait l'essai prévu avec ConvNeXt-Tiny, parce que ma question porte sur la hiérarchie et pas sur le meilleur réseau.
- Je n'ai pas optimisé w_coarse = 0,5 et beta = 10. D'autres valeurs pourraient changer le classement entre les modèles.
- Le bootstrap porte sur les images : il ne prend pas en compte toute la variabilité entre les entraînements, et 3 graines, c'est peu. Je n'ai pas non plus corrigé pour les comparaisons multiples (9 intervalles).
- Je n'ai pas testé le modèle sur des photos hors du dataset. Les scores ne valent que pour ce type de photos.
- La gravité dépend de la hiérarchie du dataset, qui ne reflète pas toujours la ressemblance réelle entre les avions.

9. Conclusion

Sur FGVC-Aircraft, donner la hiérarchie au modèle réduit les erreurs graves de 14 à 16 %, sans perte sur les variantes. Et le plus simple marche très bien : changer uniquement la cible avec des soft labels donne le même gain qu'un modèle à 3 têtes, avec des prédictions plus cohérentes.

Pour aller plus loin, je testerais une résolution plus élevée pour les variantes proches, je réglerais beta et w_coarse sur la validation, et j'évaluerais le modèle sur des photos hors du dataset.

Références

- Maji, S., Rahtu, E., Kannala, J., Blaschko, M., Vedaldi, A. (2013). Fine-Grained Visual Classification of Aircraft. arXiv:1306.5151.
- Bertinetto, L., Mueller, R., Tertikas, K., Samangooei, S., Lord, N. A. (2020). Making Better Mistakes: Leveraging Class Hierarchies with Deep Networks. CVPR.
- Tan, M., Le, Q. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. ICML.
- Selvaraju, R. R. et al. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. ICCV.